

Análise Comparativa de Algoritmos de Machine Learning na Previsão de Séries Temporais Financeiras

Silva, J.A.¹, Santos, M.B.², Oliveira, P.R.¹

¹Departamento de Ciência da Computação, Universidade de São Paulo

²Instituto de Matemática e Estatística, Universidade de São Paulo

RESUMO

Este trabalho apresenta uma análise comparativa de algoritmos de machine learning aplicados à previsão de séries temporais financeiras. Foram avaliados LSTM, GRU, Transformer e XGBoost utilizando dados de ações negociadas na B3. Os resultados demonstram que o modelo Transformer obteve o melhor desempenho, com RMSE 23% inferior ao modelo baseline. O estudo também identifica que a incorporação de características técnicas e indicadores macroeconômicos melhora significativamente a precisão das previsões.

1. INTRODUÇÃO

A previsão de séries temporais financeiras representa um dos desafios mais significativos e lucrativos na área de finanças quantitativas. Nos últimos anos, o avanço das técnicas de aprendizado de máquina tem proporcionado novas ferramentas para abordar este problema clássico.

Este artigo contribui para a literatura ao: (i) realizar uma comparação sistemática de quatro arquiteturas state-of-the-art; (ii) propor uma metodologia para feature engineering específica para o mercado brasileiro; (iii) apresentar resultados empíricos robustos utilizando dados reais da B3.

2. METODOLOGIA

2.1 Coleta de Dados

Foram coletados dados diários de 50 ações negociadas na B3 no período de janeiro de 2018 a dezembro de 2023. As variáveis incluem preço de abertura, fechamento, máxima, mínima, volume e indicadores técnicos (média móvel, RSI, MACD, Bollinger Bands).

3. RESULTADOS

Modelo	RMSE	MAE	R ²	Tempo de Treino (min)
--------	------	-----	----------------	-----------------------

LSTM	0.0234	0.0189	0.87	45
GRU	0.0251	0.0198	0.85	38
Transformer	0.0178	0.0142	0.92	67
XGBoost	0.0198	0.0156	0.89	12

4. CONCLUSÃO

Os resultados demonstram que modelos baseados em attention mechanism (Transformer) apresentam superioridade na tarefa de previsão de séries temporais financeiras, embora com maior custo computacional. Trabalhos futuros devem investigar técnicas de compressão de modelos e otimização para deploy em ambientes de produção.